Karta eksploracji danych
Co przewiduje prawy swipe w RentFriends?

Zespół: DO POTWIERDZENIA · wersja robocza do review, 2026-10-20

Podstawa liczb: zapisane wyniki notebooków (`EDA`, `users_overview`, `profile_history_overview`) i dokument techniczny (`docs/rentfriends_hipotezy_karta_eksploracji.md`). Liczby są **sprzed filtra Hyderabad (45 kont)** i sprzed wersjonowania profili (D7, D10), więc płeć, wiek i miasto pochodzą z bieżącej tabeli `users`. DO PRZELICZENIA po filtrze Hyderabad
DO POTWIERDZENIA oznacza założenie lub brak danych w artefaktach.

1. Pytanie badawcze i hipotezy

Wspólnego najmu nie obserwujemy. Dane kończą się na rozpoczęciu rozmowy, a match nie jest decyzją o najmie. Badamy więc decyzje w aplikacji.

Pytanie: które cechy pary (A, B) są związane z prawym swipe'em A→B? W szczególności: czy zgodność stylu życia przewiduje go silniej niż zgodność wieku i zainteresowań?

- **Zmienna główna:** `y_right`, czyli swipe kierunkowy A→B na profil.
- **Zmienna drugorzędna:** match, tylko dla par z zapisanymi swipe'ami obu stron.
- **Rozmowy:** tylko opisowo.

ID	Hipoteza	Co ją obali
H1	Zgodność stylu życia przewiduje `y_right` (i match) silniej niż zgodność wieku i zainteresowań.	Blok stylu życia nie daje większego przyrostu niż wiek i zainteresowania w obu kolejnościach, CI różnicy obejmuje 0 albo blok nie odróżnia się od tasowania.
H2	Płeć i wiek są związane z `y_right`. Szacujemy wielkość efektu: iloraz szans (ta sama vs różna płeć) według płci nadawcy, z CI.	CI ilorazu szans obejmuje 1. Macierz z Rys. 3 widzieliśmy przed sformułowaniem H2, więc ta część jest eksploracyjna.
H3[dod.]	Staranność bio odbiorcy (pusty/niepusty, długość; H3a) przewiduje `y_right` ponad pola strukturalne i liczbę tagów.	CI efektu obejmuje 0 po kontroli kompletności profilu i popularności. H3b (treść bio) tylko przy wolnych zasobach DO POTWIERDZENIA.

Dawne ID (dokument techniczny, notebooki): H1 = H1, H2 = H2, H3 = **H5**. H3 jest dodatkowa, bo zakres części NLP jest niepewny.[1]

2. Źródła danych

Zanonimizowany eksport z RentFriends z losowymi identyfikatorami `user_key`. Nie używamy innych platform ani scrapingu.

- **Właściciel, warunki użycia, data otrzymania:** DO POTWIERDZENIA (data statement w przygotowaniu).
- **Spójność kluczy:** `user_key` łączy `users`, `swipes` i `matches`; 100% swipe'ów na ogłoszenia łączy się z `listings`; zduplikowanych swipe'ów jest 0; match pokrywa się z wzajemnym prawym swipe'em w 99,95%.
- **Czas:** tylko numer dnia `day` (swipe'y: dni 1–113), bez godzin.

Tabela	Zawartość	Liczność
`users`	płeć (F/M/O), `age_band`, miasto, 7 pól stylu życia, tagi `interests`, bio	2065 profili
`swipes`	nadawca, cel (profil/ogłoszenie), kierunek, `day`	95 144 na profile, 21 270 na ogłoszenia
`matches`	para, `day`	733
`chats`	para, `from_match`, ogłoszenie źródłowe, dni; bez treści	2742
`listings`	miasto, typ, cena, `created_day`	294
`profile_history`	pełne snapshoty profilu w każdej wersji	4508 wersji, 2056 użytk.

3. Zakres próby

- **Jednostka:** swipe A→B na profil, a dla matcha para {A, B}. Użytkownik występuje w wielu parach, więc foldy i bootstrap robimy po użytkownikach.
- **Próba główna** (bez progu aktywności i bez wykluczania kont skrajnych, D6): 1583 swipujących z 2065 użytkowników, 95 144 swipe'ów, 7790 par z decyzją obu stron, 487 matchy. 246 matchy z jednym swipe'em jest poza modelem.
- **Wykluczenie:** 45 kont z Hyderabad (anomalia dla polskiej aplikacji) wraz z ich swipe'ami. Kategoria „inne" zostaje. DO PRZELICZENIA

[1] Odrzuciliśmy dwie hipotezy wymagające kolejności zdarzeń w ciągu dnia (dopasowanie dwustronne, zgodność selektywności; dawne H3 i H4). Dane mają tylko `day`, a po filtrach zostaje 2308 par i 87 matchy.

- **Wrażliwość:** próg ≥ 10 swipe'ów daje 7538 par i 470 matchy. Bez kont skrajnych (18 z samymi prawymi, 359 z samymi lewymi swipe'ami) zostaje 5527 par.
- **Jednorodność:** `student` ma 55% użytkowników, pasmo 18–20 54%, `search_goal` = LR 92%. Miasta: Wrocław 34%, „inne" 28%, Warszawa 15%.

4. Wyniki wstępnej eksploracji

Opis bez wnioskowania. Dane wstępne: bieżąca płeć z `users`, surowe tagi, z Hyderabad.

Lejek	Liczba	Odsetek
Swipe'y na profile	95 144	100%
Prawe swipe'y	19 495	20,49% swipe'ów
Matche	733	7,52% prawych
Matche z rozmową	269	36,70% matchy

- **Matche:** 487 z oboma swipe'ami, 246 (33,6%) z jednym.
- **Rozmowy:** 2742, z czego 269 z matcha, 163 z ogłoszenia, a 2310 bez obu (możliwy „Superlajk").
- **Ten sam dzień:** 1220 z 7790 par (15,66%) zdecydowało tego samego dnia.

Aktywność (Rys. 1)

- Mediana 26 swipe'ów na użytkownika (średnia 60,1; p95 ≈ 250; maks. 646). 231 kont (14,59%) ma mniej niż 5 swipe'ów.
- Selektywność (odsetek prawych): mediana 4,4%, średnia 17,4%.
- Duże różnice między użytkownikami uzasadniają efekty losowe i wrażliwość na konta skrajne.

Styl życia i tagi, H1 (Rys. 2)

- Pięć pól stylu życia ma 74–81% braków.
- `cleanliness` i `noise_level` mają tylko 1,0% i 1,2% braków, ale dominująca kategoria ma 53,0% i 50,4%. To może być wartość domyślna. Kody nie mają codebooka.
- Tagi: 124 surowe ciągi, w tym 54 formy emoji obok snake_case. 256 użytkowników ma oba formaty (159 z nich na limicie 9). 57% ma 9 tagów, 2,57% żadnego.
- Jaccard w 733 matchach: średnia 0,146, mediana 0,125. Liczony na surowych tagach i bez porównania z parami bez matcha (wykresy: `users_overview`, sekcja 6).

Demografia, H2 (Rys. 3, Rys. 4)

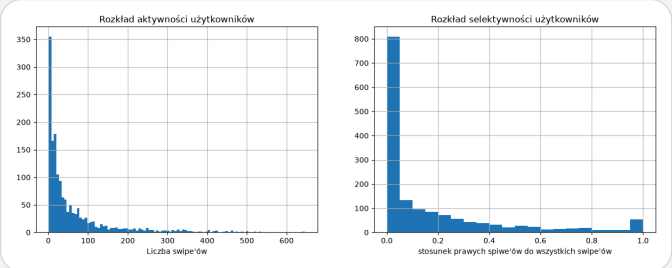
- Ta sama vs różna płeć: kobiety 20,1% vs 9,2% (F→M 8,7%, CI 8,3–9,1%), mężczyźni 19,5% vs 28,9% (M→F 29,2%).
- Żadna komórka nie jest bliska zeru. Komórki z `0` są małe (O→O: 98 swipe'ów).
- Wiek: to samo vs różne pasmo daje 21,2% vs 20,0%, ale liczy się kierunek: 18–20 → 18–20 20,4%, 18–20 → 27–30 6,6%. 65% wyświetleń dotyczy profili 18–20.

Bio, H3

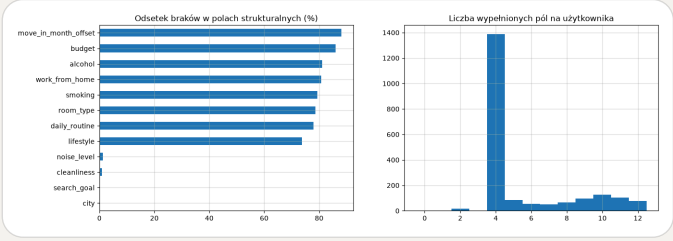
- Bio ma 1102 z 2065 profili (53,4%). Mediana 81 znaków (IQR 33–153), sufit 250.
- P(prawy): 21,5% dla odbiorców z bio, 19,2% bez bio (bez kontroli; wykres: `EDA`, „Bio").

Wersje profilu

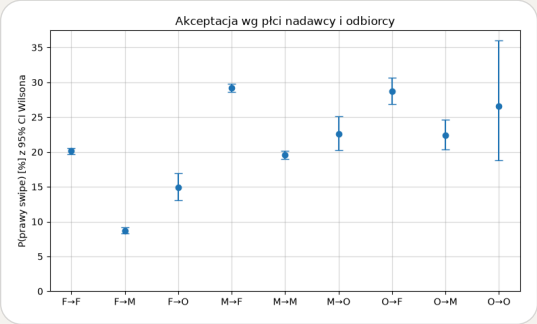
- 4508 wersji; ostatnia zgadza się z `users` w 100% pól.
- Płeć zmieniło 87 użytkowników (101 zmian, 65 do `0`), wiek 12, miasto 118. `changed_fields` pomija zmiany płci, więc porównujemy snapshoty.
- Swipe'y względem wersji: 54 597 (46,9%) z dnia pierwszej wersji, 61 118 (52,5%) z wcześniejszą wersją, 551 przed pierwszą, 148 bez historii. Liczone na 116 414 swipe'ach razem z ogłoszeniami. DO PRZELICZENIA dla 95 144 swipe'ów na profile



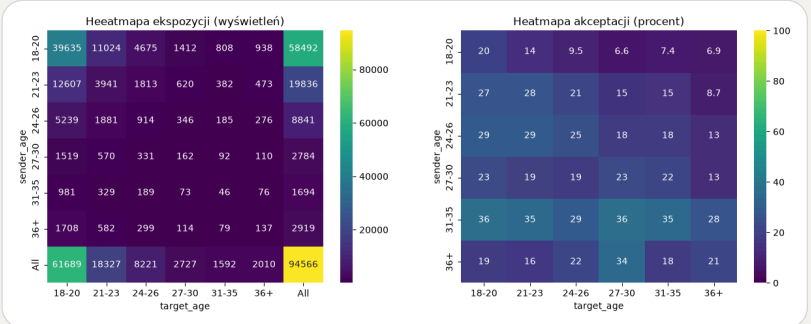
Rys. 1. Liczba swipe'ów na użytkownika (lewy) i selektywność, czyli odsetek prawych swipe'ów (prawy); 1583 użytkowników. Podstawa: swipe'y na profile, `EDA`, „Aktywność użytkowników". Z Hyderabad. Słupki przy 0 i 1 to konta skrajne (D6).



Rys. 2. Braki w polach strukturalnych `users` (lewy) i liczba wypełnionych pól na użytkownika (prawy); n = 2065. Podstawa: `EDA`, „Pola stylu życia". Niskie braki `cleanliness` i `noise_level` mogą wynikać z wartości domyślnych. Wykres obejmuje też pola spoza stylu życia.



Rys. 3. P(prawy swipe) według płci nadawcy→odbiorcy z 95% CI Wilsona; 95 144 swipe'ów. Podstawa: `EDA`, „H2: przedziały ufności". CI niezgrupowane po użytkowniku, więc zaniżone. `0` interpretujemy ostrożnie. *wstępne: bieżąca płeć z `users`, surowe tagi, z Hyderabad.*



Rys. 4. Wyświetlenia (lewy) i odsetek prawych swipe'ów (prawy) według pasma wieku nadawcy (wiersze) i odbiorcy (kolumny); 94 566 swipe'ów z `age_band`. Podstawa: `EDA`, „ekspozycji oraz stopnia akceptacji". Komórki 27+ są małe; w analizie łączymy je (D9). Z Hyderabad.

5. Plan pomiaru zjawiska

Wersja profilu w dniu swipe'a (as-of, D7). Każdy swipe dostaje flagę źródła:

- `prior_version`: swipe po dniu pierwszej wersji, czyli ostatnia wersja sprzed dnia swipe'a;
- `first_version`: swipe z dnia pierwszej wersji lub wcześniejszy, czyli wersja v1;
- `users_current`: 9 użytkowników bez historii, czyli bieżący `users`.

Bloki zmiennych (1–3 skalary na blok, D16)

- **Demografia:** płeć nadawcy × odbiorcy (`0` jako osobna kategoria), ta sama płeć, różnica pasm wieku ze znakiem i to samo pasmo (pasma 27+ połączone).
- **Styl życia:** zgodność 7 pól, gdy obie strony je wypełniły („brak danych" jako kategoria); konflikt kierunkowy tagów (np. `non_smoker` vs `smoker/vapes`); liczba wspólnych tagów. Pole ma pierwszeństwo przed tagiem, a tag uzupełnia braki.
- **Zainteresowania:** tagi hobby po ujednoliceniu i deduplikacji DO POTWIERDZENIA, czyli Jaccard i liczba tagów. `student` to status; zwierzęta i `extrovert/introvert` należą do stylu życia.
- **Bio (H3a):** pusty/niepusty, długość liczona z tekstu.

Model i testy

- Regresja logistyczna dla `y_right`; match w modelu drugorzędnym (7790 par).
- Estymator DO POTWIERDZENIA: krzyżowe efekty losowe nadawcy i odbiorcy albo błędy klastrowane.
- Kontrole: `same_city`, a popularność i hojność przez efekty losowe DO POTWIERDZENIA.
- Walidacja w foldach po użytkownikach; metryki logloss, AUC, AUC-PR.
- **H1:** ΔlogLoss i ΔAUC po dodaniu bloku, w obu kolejnościach, z CI z bootstrapu po użytkownikach i baseline'em z tasowania bloku. Analiza per pole jest drugorzędna.
- **H2:** iloraz szans z CI. **H3:** efekt bio z kontrolą liczby tagów i kompletności profilu.

Instrument AI

- Agent AI proponuje ujednolicenie tagów (54 formy emoji → kanoniczne) i ich podział, a człowiek ustala wersję końcową.
- Walidacja: zgodność agenta z człowiekiem (miara DO POTWIERDZENIA). Propozycje agenta zapisujemy przed zamrożeniem codebooka.
- Ewentualne NLP w H3: gold standard z ręcznie oznaczonej próbki, lokalnie. Rozmiar próbki i adnotatorzy są nieustaleni.

Analizy wrażliwości

1. Próg ≥ 10 swipe'ów i bez kont skrajnych.
2. Tylko swipe'y z `prior_version`; cechy z bieżącego `users`.
3. Z kontami Hyderabad.
4. Bez kategorii „brak danych" oraz bez `cleanliness/noise_level`.
5. Dla matcha: z 246 matchami z jednym swipe'em.

6. Ograniczenia danych i możliwe źródła błędu

- **Match ≠ najem.** Wnioski dotyczą decyzji w aplikacji. Badamy związki, nie przyczyny.
- **Ekspozycja:** widzimy tylko pary pokazane przez feed. Filtry i ranking mogą zawężać wariancję, np. płci.
- **Czas tylko w dniach:** dla 46,9% swipe'ów wersja v1 jest przybliżeniem; 551 swipe'ów jest sprzed pierwszej wersji, a dzień zerowy jest nieznany.
- **Pomiar stylu życia:** dużo braków, brak codebooka, możliwe wartości domyślne. Bloki mają różną rozdzielczość i są skorelowane, więc porównujemy je w obu kolejnościach.
- **Tagi:** sufit 9 tagów i duplikaty formatów zniekształcają podobieństwo; Jaccard zależy od liczby tagów.
- **Płeć `0`:** powstaje głównie przez zmianę płci, ma małe komórki i niejasne znaczenie.
- **Brak zdjęć:** popularność modelujemy efektem losowym, ale nie znamy jej źródła.

- **Jednorodna próba** (studenci, 18–20, kilka miast) ogranicza uogólnienie.
- **Wielość porównań:** jedna główna definicja zmiennej na blok, ustalona przed modelowaniem.

7. Wykonalność w skali kursu

- **Liczności:** `y_right` ma 95 144 obserwacji, a match 487 zdarzeń. Reguła 10 zdarzeń na zmienną pozwala na ok. 47 zmiennych (dokument techniczny, próg ≥ 10). Planujemy 1–3 skalary na blok.
- **Rdzeń:** H1 i H2 na `y_right`. H3a to jeden blok więcej w tym samym modelu; H3b tylko przy wolnym czasie.
- **Przed modelowaniem:** ujednolicenie tagów, cechy as-of, filtr Hyderabad.
- **Podział zadań na M2 i M3:** DO POTWIERDZENIA

Pytań do dostawcy nie da się zadać przed kartą, więc otwarte kwestie opisujemy scenariuszami:

Kwestia	Jeśli… , to…
Działanie feedu (filtry, ranking, widoczność lajka)	Jeśli feed filtruje płeć lub wiek, H2 opisuje ustawienia filtrów, a efekty są zaniżone. Jeśli jest losowy, opisuje preferencje w obserwowanej puli.
Widoczność tagów i bio na karcie	Jeśli są niewidoczne, brak efektu w H1 lub H3 nie oznacza braku znaczenia, a hipoteza staje się nietestowalna.
246 matchy z jednym swipe'em; Superlajk (2310 rozmów)	Jeśli braki są losowe, model na 487 matchach jest reprezentatywny. Jeśli nie, zawężamy wniosek o matchu i sprawdzamy wrażliwość.
Kody pól stylu życia; domyślne `cleanliness`/ `noise_level`	Jeśli to wartości domyślne, wyłączamy te pola. Bez codebooka używamy tylko zgodności równości.
Znaczenie `0`, zmiany płci	Jeśli `0` to artefakt, wyniki dla `0` podajemy tylko opisowo.
Dzień zerowy; swipe'y z dnia pierwszej wersji i wcześniejsze	Jeśli v1 powstaje przy rejestracji, przypisanie v1 jest poprawne. Jeśli nie, opieramy się na wrażliwości dla `prior_version`.

8. Dane osobowe i ujawnienie użycia AI

Dane osobowe

- Bio przetwarzamy tylko zagregowanie, bez wyświetlania treści.
- Przesiew regułami w wersjach bio: cyfry w 9,27% wersji, `@` lub link w 1 wersji, ciągów 9+ cyfr brak. Pełny audyt przed użyciem tekstu.
- NLP tylko lokalnie, bez zewnętrznych API. Dane nie trafiają do repozytorium, a raport pokazuje tylko agregaty.

Użycie AI

- Kartę przygotował agent Claude Code według decyzji zespołu (`docs/prompts/m1-generation-plan.md`). Review zespołu: DO POTWIERDZENIA
- Wcześniejsze użycie AI opisuje `docs/ai-disclosure.md`, a logi sesji leżą w `logs/ai/`.