Karta eksploracji danych
Co przewiduje prawy swipe w RentFriends?

Zespół: Dominik Czech, Michał Jankowski, Jakub Smolarczyk, 2026-10-20

Podstawa liczb: zapisane wyniki notebooków (`EDA`, `users_overview`, `profile_history_overview`) i dokument techniczny (`docs/rentfriends_hipotezy_karta_eksploracji.md`). Liczby są **sprzed filtra Hyderabad (45 kont)** i sprzed wersjonowania profili, więc płeć, wiek i miasto pochodzą z bieżącej tabeli `users`.

1. Pytanie badawcze i hipotezy

Wspólnego najmu nie obserwujemy. Dane kończą się na rozpoczęciu rozmowy, a match nie jest decyzją o najmie. Badamy więc decyzje w aplikacji.

Pytanie: które cechy pary (A, B) są związane z prawym swipe'em A→B? W szczególności: czy zgodność stylu życia przewiduje go silniej niż zgodność wieku i zainteresowań?

- **Zmienna główna:** `y_right`, czyli swipe kierunkowy A→B na profil.
- **Zmienna drugorzędna:** match, tylko dla par z zapisanymi swipe'ami obu stron.
- **Rozmowy:** tylko opisowo.

ID	Hipoteza	Co ją obali
H1	Zgodność stylu życia przewiduje `y_right` (i match) silniej niż zgodność wieku i zainteresowań.	Blok stylu życia nie daje większego przyrostu niż wiek i zainteresowania w obu kolejnościach, CI różnicy obejmuje 0 albo blok nie odróżnia się od tasowania.
H2	Płeć i wiek są związane z `y_right`. Szacujemy wielkość efektu: iloraz szans (ta sama vs różna płeć) według płci nadawcy, z CI.	CI ilorazu szans obejmuje 1. Macierz z Rys. 5 widzieliśmy przed sformułowaniem H2, więc ta część jest eksploracyjna.
H3[dod.]	Staranność bio odbiorcy (pusty/niepusty, długość; H3a) przewiduje `y_right` ponad pola strukturalne i liczbę tagów.	CI efektu obejmuje 0 po kontroli kompletności profilu i popularności. H3b (treść bio) tylko przy wolnych zasobach

Dawne ID (dokument techniczny, notebooki): H1 = H1, H2 = H2, H3 = **H5**. H3 jest dodatkowa, bo zakres części NLP jest niepewny.[1]

2. Źródła danych

Zanonimizowany eksport z RentFriends z losowymi identyfikatorami `user_key`. Nie używamy innych platform ani scrapingu.

- **Właściciel, warunki użycia, data otrzymania:** (data statement w przygotowaniu).
- **Struktura:** sześć tabel powiązanych kluczami użytkownika i ogłoszenia (Rys. 1); kolumny opisują Tab. 1, Tab. 2 i Tab. 3.
- **Spójność kluczy:** `user_key` łączy `users`, `swipes` i `matches`; 100% swipe'ów na ogłoszenia łączy się z `listings`; zduplikowanych swipe'ów jest 0; match pokrywa się z wzajemnym prawym swipe'em w 99,95%.
- **Czas:** tylko numer dnia `day` (swipe'y: dni 1–113), bez godzin.

3. Zakres próby

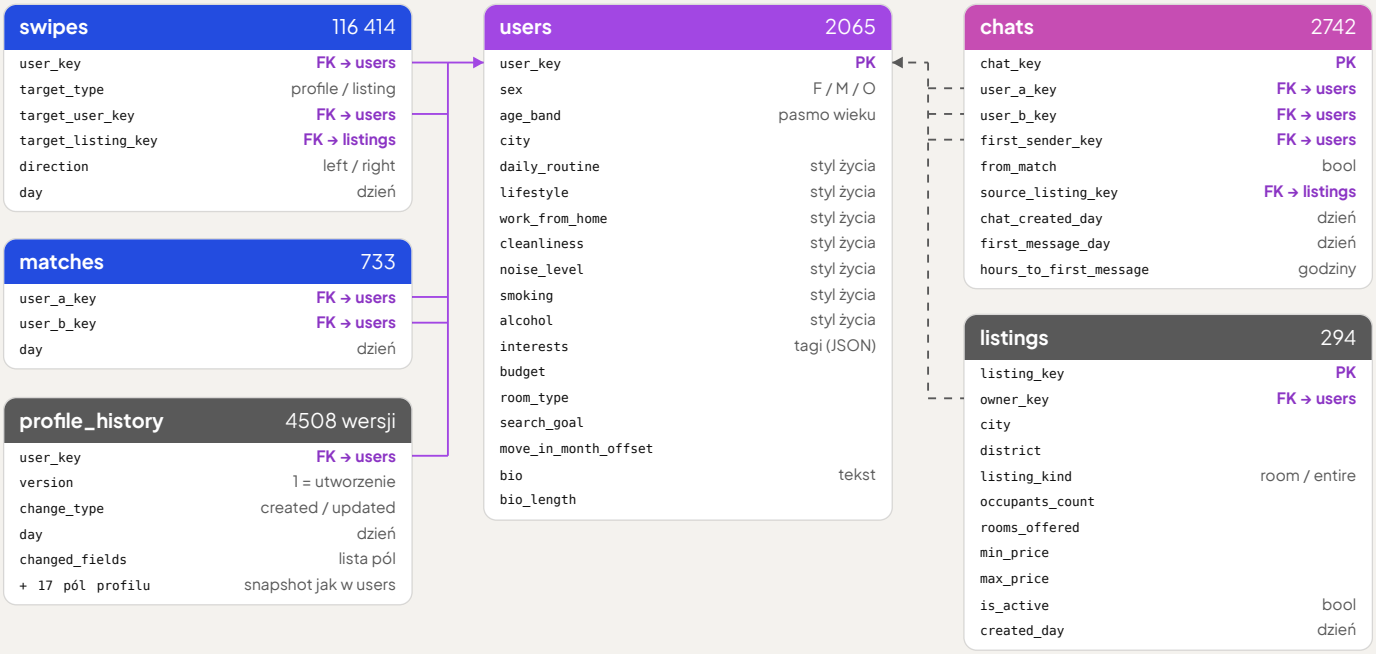
- **Jednostka:** swipe A→B na profil, a dla matcha para {A, B}. Użytkownik występuje w wielu parach, więc foldy i bootstrap robimy po użytkownikach.
- **Próba główna** (bez progu aktywności i bez wykluczania kont skrajnych): 1583 swipujących z 2065 użytkowników, 95 144 swipe'ów, 7790 par z decyzją obu stron, 487 matchy. 246 matchy z jednym swipe'em jest poza modelem.
- **Wykluczenie:** 45 kont z Hyderabad (anomalia dla polskiej aplikacji) wraz z ich swipe'ami. Kategoria „inne" zostaje.
- **Wrażliwość:** próg ≥ 10 swipe'ów daje 7538 par i 470 matchy. Bez kont skrajnych (18 z samymi prawymi, 359 z samymi lewymi swipe'ami) zostaje 5527 par.
- **Jednorodność:** `student` ma 55% użytkowników, pasmo 18–20 54%, `search_goal` = LR 92%. Miasta: Wrocław 34%, „inne" 28%, Warszawa 15%.

4. Wyniki wstępnej eksploracji

Opis bez wnioskowania. Dane wstępne: bieżąca płeć z `users`, surowe tagi, z Hyderabad.

Struktura tabel. Znaczenia kolumn pochodzą z notebooków `users_overview` i `profile_history_overview`, typy z `data/tables_metadata.json`, a braki z `users_overview` (sekcja 3).

[1] Odrzuciliśmy dwie hipotezy wymagające kolejności zdarzeń w ciągu dnia (dopasowanie dwustronne, zgodność selektywności; dawne H3 i H4). Dane mają tylko `day`, a po filtrach zostaje 2308 par i 87 matchy.



Rys. 1. Schemat tabel i powiązań kluczy (wszystkie kolumny według `data/tables_metadata.json`; `profile_history` powtarza 17 pól profilu z `users`). W nagłówkach liczba wierszy: `swipes` = 95 144 na profile + 21 270 na ogłoszenia. Linia ciągła: spójność kluczy sprawdzona w EDA. Linia przerywana: powiązanie według nazw kolumn, niesprawdzone. Relacje z `listings` (FK → listings) nie są narysowane; swipe'y na ogłoszenia łączą się z `listings` w 100%. Liczności sprzed filtra Hyderabad.

Lejek	Liczba	Odsetek
Swipe'y na profile	95 144	100%
Prawe swipe'y	19 495	20,49% swipe'ów
Matche	733	7,52% prawych
Matche z rozmową	269	36,70% matchy

- **Matche:** 487 z oboma swipe'ami, 246 (33,6%) z jednym.
- **Rozmowy:** 2742, z czego 269 z matcha, 163 z ogłoszenia, a 2310 bez obu (do skonsultowania z dostawcą).
- **Ten sam dzień:** 1220 z 7790 par (15,66%) zdecydowało tego samego dnia.

Tab. 1. Kolumny tabeli `users` (2065 profili, 18 kolumn), stan bieżący z eksportu.

Kolumny	Znaczenie	Braki	Uwagi
`user_key`	pseudonimizowany identyfikator (UUID)	0%	unikalny w tabeli
`sex`	płeć: F / M / O	0%	`O` ma 73 osoby
`age_band`	pasmo wieku (18–20 … 36+), nie lata	0,4%	6 pasm
`city`	miasto; „inne" = pozostałe	0%	10 wartości, w tym Hyderabad (45 kont)
`daily_routine`, `lifestyle`, `work_from_home`, `smoking`, `alcohol`	kody stylu życia	73,8–81,1%	brak codebooka
`cleanliness`, `noise_level`	kody stylu życia	1,0% / 1,2%	brak codebooka; możliwa wartość domyślna
`interests`	lista tagów JSON (0–9)	0%	2,57% pustych list; 124 surowe ciągi
`budget`	miesięczny budżet	86,0%	wartości skrajne do sprawdzenia
`room_type`, `search_goal`	kody (`SN/SH`; `LR/HA`)	78,6% / 0%	znaczenie do potwierdzenia; LR 92%
`move_in_month_offset`	miesiące do przeprowadzki	88,1%	są wartości ujemne
`bio`, `bio_length`	opis i jego długość w znakach	46,6% / 0%	treść niewyświetlana; sufit 250

Tab. 2. Kolumny tabeli `profile_history` (4508 wersji, 22 kolumny).

Kolumny	Znaczenie	Uwagi
`user_key`	identyfikator jak w `users`	2056 użytkowników; 9 z `users` bez historii
`version`	numer wersji użytkownika, 1 = utworzenie	maks. 30
`change_type`	`created` (tylko wersja 1) lub `updated`	2056 utworzeń, 2452 aktualizacji
`day`	numer dnia wersji; data początkowa nieznana	dni 2–113
`changed_fields`	pola zmienione względem poprzedniej wersji	nie odnotowuje `sex`; `city` 541 razy przy 303 zmianach
17 pól profilu, w tym `bio`	pełny snapshot profilu w danej wersji	ostatnia wersja zgodna z `users` w 100% pól

Tab. 3. Kolumny tabel zdarzeń i ogłoszeń. Typy: klucze UUID, dni jako liczby całkowite.

Tabela	Kolumny	Znaczenie i uwagi
swipes	user_key	nadawca swipe'a
	target_type, target_user_key, target_listing_key	cel: profil (odbiorca) albo ogłoszenie
	direction	left / right; prawe: 20,49% swipe'ów na profile
	day	numer dnia (1–113), bez godzin
matches	user_a_key, user_b_key	para; 487 z 733 matchy ma zapisane oba swipe'y
	day	dzień matcha (4–113)
chats	chat_key, user_a_key, user_b_key, first_sender_key	rozmowa, para i osoba, która napisała pierwsza; bez treści
	from_match, source_listing_key	źródło: match (269) albo ogłoszenie (163); 2310 bez obu
	chat_created_day, first_message_day	dni (4–113)
	hours_to_first_message	godziny do pierwszej wiadomości: jedyna miara czasu poniżej dnia
listings	listing_key, owner_key	ogłoszenie i jego właściciel
	city, district, listing_kind	lokalizacja; room / entire
	occupants_count, rooms_offered, min_price, max_price, is_active	min_price: mediana 1750, maks. 500 000 (do czyszczenia)
	created_day	dzień utworzenia (12–113)

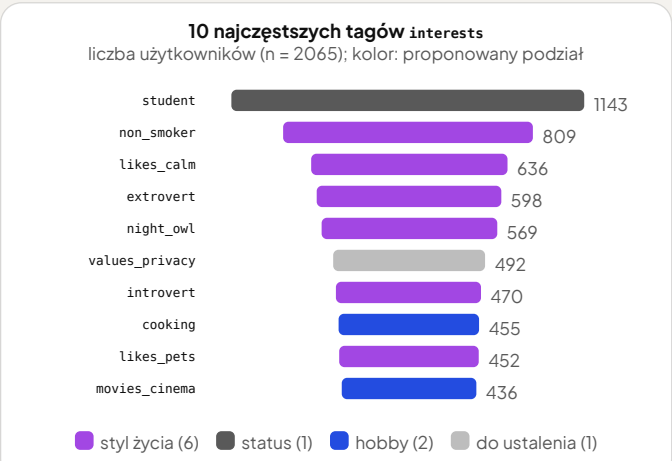
Aktywność (Rys. 3)

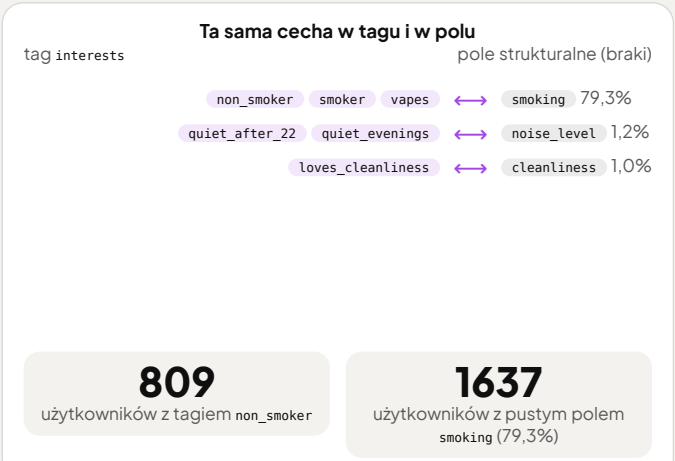
- Mediana 26 swipe'ów na użytkownika (średnia 60,1; p95 ≈ 250; maks. 646). 231 kont (14,59%) ma mniej niż 5 swipe'ów.
- Selektywność (odsetek prawych): mediana 4,4%, średnia 17,4%.
- Duże różnice między użytkownikami uzasadniają efekty losowe i wrażliwość na konta skrajne.

Styl życia i tagi, H1 (Rys. 2, Rys. 4)

> **Styl życia jest zapisany w dwóch miejscach:** w 7 polach strukturalnych, które są w większości puste, i w tagach interests, które mieszają styl życia z hobby i statusem. Bez rozdzielenia tagów blok „zainteresowań" w H1 mierzyłby po części styl życia.

- **Pola strukturalne:** pięć pól stylu życia ma 74–81% braków. cleanliness i noise_level mają tylko 1,0% i 1,2% braków, ale dominująca kategoria ma 53,0% i 50,4%, co może być wartością domyślną. Kody nie mają codebooka.
- **Tagi interests to nie tylko zainteresowania:** wśród 10 najczęstszych tagów 6 opisuje styl życia (np. non_smoker 809, likes_calm 636, night_owl 569 użytkowników), 1 status (student, 1143), a tylko 2 to hobby (cooking, movies_cinema).
- **Ta sama cecha w dwóch miejscach:** tag non_smoker ma 809 użytkowników, a pole smoking jest puste u 1637 (79,3%). Podobne pary: quiet_after_22/quiet_evenings i noise_level, loves_cleanliness i cleanliness.
- **Skutek dla H1:** Jaccard tagów w 733 matchach (średnia 0,146, mediana 0,125) liczono na surowych tagach, więc obejmuje też styl życia i status. Przed modelem dzielimy tagi (D12), polu dajemy pierwszeństwo przed tagiem (D13) i ujednolicamy formaty.
- **Formaty tagów:** 124 surowe ciągi, w tym 54 formy emoji obok snake_case. 256 użytkowników ma oba formaty (159 z nich na limicie 9). 57% ma 9 tagów, 2,57% żadnego.





Rys. 2. Styl życia w tagach interests i w polach strukturalnych. Lewy: 10 najczęstszych surowych tagów (EDA, „Analiza zainteresowań"). Kolor to wstępny podział według D12, D15 i dokumentu technicznego (values_privacy nieprzypisany); cooking i movies_cinema jako hobby to propozycja przed zamrożeniem codebooka. Prawy: pary tag–pole wskazane w dokumencie technicznym (H1, plan pomiaru) i braki pól z users_overview. Liczności tagów pozostałych par nie były liczone. Surowe tagi z duplikatami formatów, z Hyderabad.

Demografia, H2 (Rys. 5, Rys. 6)

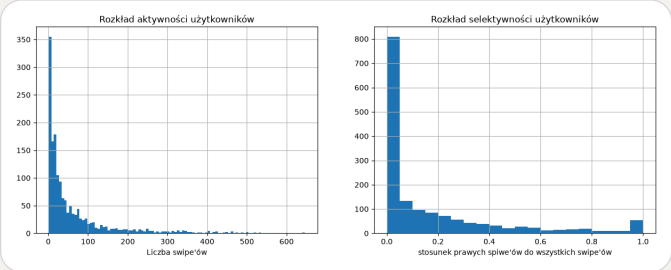
- Ta sama vs różna płeć: kobiety 20,1% vs 9,2% (F→M 8,7%, CI 8,3–9,1%), mężczyźni 19,5% vs 28,9% (M→F 29,2%).
- Żadna komórka nie jest bliska zeru. Komórki z `0` są małe (O→O: 98 swipe'ów).
- Wiek: to samo vs różne pasmo daje 21,2% vs 20,0%, ale liczy się kierunek: 18–20 → 18–20 20,4%, 18–20 → 27–30 6,6%. 65% wyświetleń dotyczy profili 18–20.

Bio, H3

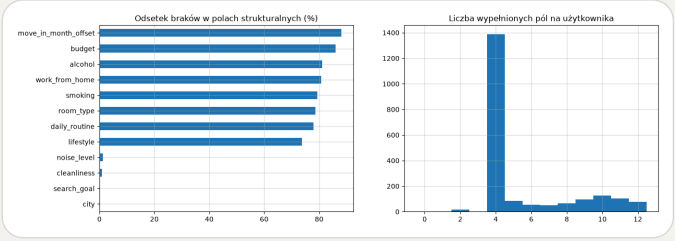
- Bio ma 1102 z 2065 profili (53,4%). Mediana 81 znaków (IQR 33–153), sufit 250.
- P(prawy): 21,5% dla odbiorców z bio, 19,2% bez bio (bez kontroli; wykres: `EDA`, „Bio").

Wersje profilu

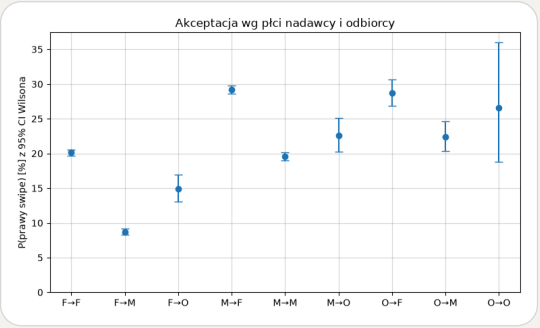
- 4508 wersji; ostatnia zgadza się z `users` w 100% pól.
- Płeć zmieniło 87 użytkowników (101 zmian, 65 do `0`), wiek 12, miasto 118. `changed_fields` pomija zmiany płci, więc porównujemy snapshoty.
- Swipe'y względem wersji: 54 597 (46,9%) z dnia pierwszej wersji, 61 118 (52,5%) z wcześniejszą wersją, 551 przed pierwszą, 148 bez historii. Liczone na 116 414 swipe'ach razem z ogłoszeniami. DO PRZELICZENIA dla 95 144 swipe'ów na profile



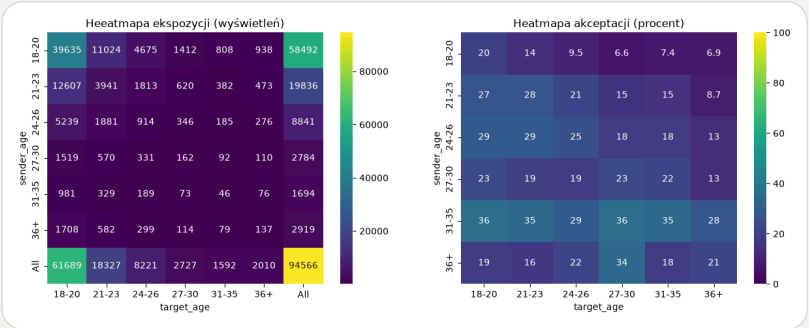
Rys. 3. Liczba swipe'ów na użytkownika (lewy) i selektywność, czyli odsetek prawych swipe'ów (prawy); 1583 użytkowników. Podstawa: swipe'y na profile, `EDA`, „Aktywność użytkowników". Z Hyderabad. Słupki przy 0 i 1 to konta skrajne (D6).



Rys. 4. Braki w polach strukturalnych `users` (lewy) i liczba wypełnionych pól na użytkownika (prawy); n = 2065. Podstawa: `EDA`, „Pola stylu życia". Niskie braki `cleanliness` i `noise_level` mogą wynikać z wartości domyślnych. Wykres obejmuje też pola spoza stylu życia.



Rys. 5. P(prawy swipe) według płci nadawcy→odbiorcy z 95% CI Wilsona; 95 144 swipe'ów. Podstawa: `EDA`, „H2: przedziały ufności". CI niezgrupowane po użytkowniku, więc zaniżone. `0` interpretujemy ostrożnie. *wstępne: bieżąca płeć z `users`, surowe tagi, z Hyderabad.*



Rys. 6. Wyświetlenia (lewy) i odsetek prawych swipe'ów (prawy) według pasma wieku nadawcy (wiersze) i odbiorcy (kolumny); 94 566 swipe'ów z `age_band`. Podstawa: `EDA`, „ekspozycji oraz stopnia akceptacji". Komórki 27+ są małe; w analizie łączymy je (D9). Z Hyderabad.

5. Plan pomiaru zjawiska

Wersja profilu w dniu swipe'a. Każdy swipe dostaje flagę źródła:

- `prior_version`: swipe po dniu pierwszej wersji, czyli ostatnia wersja sprzed dnia swipe'a;
- `first_version`: swipe z dnia pierwszej wersji lub wcześniejszy, czyli wersja v1;
- `users_current`: 9 użytkowników bez historii, czyli bieżący `users`.

Bloki zmiennych (1–3 skalary na blok, D16)

- **Demografia:** płeć nadawcy × odbiorcy (`0` jako osobna kategoria), ta sama płeć, różnica pasm wieku ze znakiem i to samo pasmo (pasma 27+ połączone).
- **Styl życia:** zgodność 7 pól, gdy obie strony je wypełniły („brak danych" jako kategoria); konflikt kierunkowy tagów (np. `non_smoker` vs `smoker/vapes`); liczba wspólnych tagów. Pole ma pierwszeństwo przed tagiem, a tag uzupełnia braki.
- **Zainteresowania:** tagi hobby po ujednoliceniu i deduplikacji, czyli Jaccard i liczba tagów. `student` to status; zwierzęta i `extrovert/introvert` należą do stylu życia.
- **Bio (H3a):** pusty/niepusty, długość liczona z tekstu.

Model i testy

- Regresja logistyczna dla `y_right`; match w modelu drugorzędnym (7790 par).
- Estymator: regresja logistyczna z krzyżowymi efektami losowymi (wyraz wolny nadawcy i odbiorcy) dla H2 i H3. Dla H1 pooled logit z błędami klastrowanymi dwukierunkowo (nadawca, odbiorca), oceniany w foldach po użytkownikach. Jeśli GLMM nie

osiągnie zbieżności, H2 i H3 liczymy pooled logitem z klastrowaniem dwukierunkowym, a H3 raportujemy bez twierdzenia o kontroli popularności.

- Kontrole: same_city (trzy poziomy: to samo miasto / inne / nieznane dla „inne"). Popularność i hojność jako efekty losowe odbiorcy i nadawcy w GLMM.
- Walidacja w foldach po użytkownikach; metryki logloss, AUC, AUC-PR.
- **H1:** ΔlogLoss i ΔAUC po dodaniu bloku, w obu kolejnościach, z CI z bootstrapu po użytkownikach i baseline'em z tasowania bloku. Analiza per pole jest drugorzędna.
- **H2:** iloraz szans z CI. **H3:** efekt bio z kontrolą liczby tagów i kompletności profilu.

Instrument AI

- Normalizacja tagów (124 surowe ciągi, w tym 54 formy emoji → kanoniczne snake_case): agent generuje mapowanie, człowiek je przegląda i poprawia. Miara: odsetek mapowań poprawionych przez człowieka, z listą korekt.
- Podział tagów (styl życia / status / hobby / do ustalenia): agent proponuje etykiety, człowiek etykietuje niezależnie, bez wglądu w propozycje agenta. Miara: κ Cohena agent–człowiek z 95% CI (bootstrap po tagach), uzupełniona o odsetek zgodności i macierz pomyłek.
- Propozycje agenta zapisujemy przed zamrożeniem codebooka. Wersję końcową ustala człowiek, a rozbieżności są raportowane, nie ukrywane.
- Ewentualne NLP w H3: gold standard z ręcznie oznaczonej próbki, lokalnie. Rozmiar próbki i adnotatorzy są nieustaleni.

Analizy wrażliwości

1. Próg ≥ 10 swipe'ów i bez kont skrajnych.
2. Tylko swipe'y z `prior_version`; cechy z bieżącego `users`.
3. Z kontami Hyderabad.
4. Bez kategorii „brak danych" oraz bez `cleanliness/noise_level`.
5. Dla matcha: z 246 matchami z jednym swipe'em.

6. Ograniczenia danych i możliwe źródła błędu

- **Match ≠ najem.** Wnioski dotyczą decyzji w aplikacji. Badamy związki, nie przyczyny.
- **Ekspozycja:** widzimy tylko pary pokazane przez feed. Filtry i ranking mogą zawężać wariancję, np. płci.
- **Czas tylko w dniach:** dla 46,9% swipe'ów wersja v1 jest przybliżeniem; 551 swipe'ów jest sprzed pierwszej wersji, a dzień zerowy jest nieznany.
- **Pomiar stylu życia:** dużo braków, brak codebooka, możliwe wartości domyślne. Bloki mają różną rozdzielczość i są skorelowane, więc porównujemy je w obu kolejnościach.
- **Tagi:** sufit 9 tagów i duplikaty formatów zniekształcają podobieństwo; Jaccard zależy od liczby tagów.
- **Płeć `0`:** powstaje głównie przez zmianę płci, ma małe komórki i niejasne znaczenie.
- **Brak zdjęć:** popularność modelujemy efektem losowym, ale nie znamy jej źródła.
- **Jednorodna próba** (studenci, 18–20, kilka miast) ogranicza uogólnienie.
- **Wielość porównań:** jedna główna definicja zmiennej na blok, ustalona przed modelowaniem.

7. Wykonalność w skali kursu

- **Liczności:** `y_right` ma 95 144 obserwacji, a match 487 zdarzeń. Reguła 10 zdarzeń na zmienną pozwala na ok. 47 zmiennych (dokument techniczny, próg ≥ 10). Planujemy 1–3 skalary na blok.
- **Rdzeń:** H1 i H2 na `y_right`. H3a to jeden blok więcej w tym samym modelu; H3b tylko przy wolnym czasie.
- **Przed modelowaniem:** ujednolicenie tagów, cechy as-of, filtr Hyderabad.

Pytań do dostawcy nie da się zadać przed kartą, więc otwarte kwestie opisujemy scenariuszami:

Tab. 4. Podział zadań na M2 i M3. Analizy wrażliwości numerowane jak w sekcji 5.

Osoba i rola	M2: raport z metodologią i pierwszymi wynikami	M3: plakat, notatka, prezentacja i obrony
Dominik Czech lead badawczy	pytanie, hipotezy i spójność wniosku; próbny fit estymatora (GLMM); **analiza H2** (iloraz szans z CI)	główny wynik i wniosek na plakacie; notatka dla odbiorcy spoza zespołu; **wrażliwość 5** (match z 246 matchami z jednym swipe'em)
osoba 2 inżynier danych	data statement, zgodność z RODO i regulaminami, filtr Hyderabad; cechy as-of i flagi wersji profilu; przeliczenie liczb na 95 144 swipe'ach; reguła foldów dla par	**analiza H3** (bio); **wrażliwość 2 i 3** (`prior_version`; z Hyderabad); sekcja o danych i ograniczeniach na plakacie
osoba 3 inżynier pipelinu	codebook, normalizacja i podział tagów, gold standard, κ agent–człowiek, analiza błędów; **analiza H1** (ΔlogLoss, ΔAUC, bootstrap po użytkownikach, tasowanie bloku)	**wrażliwość 1 i 4** (próg ≥ 10 i bez kont skrajnych; bez „brak danych" oraz bez `cleanliness/noise_level`); wizualizacje H1 z CI

Kwestia	Jeśli…, to…
Działanie feedu (filtry, ranking, widoczność lajka)	Jeśli feed filtruje płeć lub wiek, H2 opisuje ustawienia filtrów, a efekty są zaniżone. Jeśli jest losowy, opisuje preferencje w obserwowanej puli.
Widoczność tagów i bio na karcie	Jeśli są niewidoczne, brak efektu w H1 lub H3 nie oznacza braku znaczenia, a hipoteza staje się nietestowalna.
246 matchy z jednym swipe'em; Rozmowy bez matcha (2310 rozmów)	Jeśli braki są losowe, model na 487 matchach jest reprezentatywny. Jeśli nie, zawężamy wniosek o matchu i sprawdzamy wrażliwość.
Kody pól stylu życia; domyślne `cleanliness`/`noise_level`	Jeśli to wartości domyślne, wyłączamy te pola. Bez codebooka używamy tylko zgodności równości.
Znaczenie `0`, zmiany płci	Jeśli `0` to artefakt, wyniki dla `0` podajemy tylko opisowo.
Dzień zerowy; swipe'y z dnia pierwszej wersji i wcześniejsze	Jeśli v1 powstaje przy rejestracji, przypisanie v1 jest poprawne. Jeśli nie, opieramy się na wrażliwości dla `prior_version`.

8. Dane osobowe i ujawnienie użycia AI

Dane osobowe

- Bio przetwarzamy tylko zagregowanie, bez wyświetlania treści.
- Przesiew regułami w wersjach bio: cyfry w 9,27% wersji, `@` lub link w 1 wersji, ciągów 9+ cyfr brak. Pełny audyt przed użyciem tekstu.
- NLP tylko lokalnie, bez zewnętrznych API. Dane nie trafiają do repozytorium, a raport pokazuje tylko agregaty.

Użycie AI

- Kartę przygotował agent Claude Code według decyzji zespołu (`docs/prompts/m1-generation-plan.md`). Review zespołu: DO POTWIERDZENIA
- Wcześniejsze użycie AI opisuje `docs/ai-disclosure.md`, a logi sesji leżą w `logs/ai/`.