Analiza Mediów Cyfrowych · kamień milowy M1

Karta eksploracji danych
Co przewiduje prawy swipe w RentFriends?

Zespół: Dominik Czech, Michał Jankowski, Jakub Smolarczyk, 2026-10-20

Repozytorium: https://github.com/banacchini/digital-media-analysis

Podstawa liczb: zapisane wyniki notebooków (`EDA`, `users_overview`, `profile_history_overview`) i dokument techniczny (`docs/rentfriends_hipotezy_karta_eksploracji.md`). Liczby są **sprzed filtra Hyderabad (45 kont)** i sprzed wersjonowania profili, więc płeć, wiek i miasto pochodzą z bieżącej tabeli `users`.

1. Pytanie badawcze i hipotezy

Wspólnego najmu nie obserwujemy. Dane kończą się na rozpoczęciu rozmowy, a match nie jest decyzją o najmie. Badamy więc decyzje w aplikacji.

Pytanie: które cechy pary (A, B) są związane z prawym swipe'em A→B? W szczególności: czy zgodność stylu życia przewiduje go silniej niż zgodność wieku i zainteresowań?

- **Zmienna główna:** `y_right`, czyli swipe kierunkowy A→B na profil.
- **Zmienna drugorzędna:** match, tylko dla par z zapisanymi swipe'ami obu stron.
- **Rozmowy:** tylko opisowo.

ID	Hipoteza	Co ją obali
H1	Zgodność stylu życia przewiduje `y_right` (i match) silniej niż zgodność wieku i zainteresowań.	Blok stylu życia nie daje większego przyrostu niż wiek i zainteresowania w obu kolejnościach, CI różnicy obejmuje 0 albo blok nie odróżnia się od tasowania.
H2	Płeć i wiek są związane z `y_right`. Szacujemy wielkość efektu: iloraz szans (ta sama vs różna płeć) według płci nadawcy, z CI.	CI ilorazu szans obejmuje 1. Macierz z Rys. 2 widzieliśmy przed sformułowaniem H2, więc ta część jest eksploracyjna.
H3[dod.]	Staranność bio odbiorcy (pusty/niepusty, długość; H3a) przewiduje `y_right` ponad pola strukturalne i liczbę tagów.	CI efektu obejmuje 0 po kontroli kompletności profilu i popularności. H3b (treść bio) tylko przy wolnych zasobach.

Dawne ID (dokument techniczny, notebooki): H1 = H1, H2 = H2, H3 = **H5**. H3 jest dodatkowa, bo zakres części NLP jest niepewny.[1]

2. Źródła danych

Zanonimizowany eksport z RentFriends z losowymi identyfikatorami `user_key`. Nie używamy innych platform ani scrapingu.

- **Właściciel, warunki użycia, data otrzymania:** opisze je data statement (w przygotowaniu).
- **Struktura:** sześć tabel (`users`, `profile_history`, `swipes`, `matches`, `chats`, `listings`) powiązanych kluczami `user_key` i `listing_key`.
- **Spójność kluczy:** `user_key` łączy `users`, `swipes` i `matches`; 100% swipe'ów na ogłoszenia łączy się z `listings`; zduplikowanych swipe'ów jest 0; match pokrywa się z wzajemnym prawym swipe'em w 99,95%.
- **Czas:** tylko numer dnia `day` (swipe'y: dni 1–113), bez godzin.

3. Zakres próby

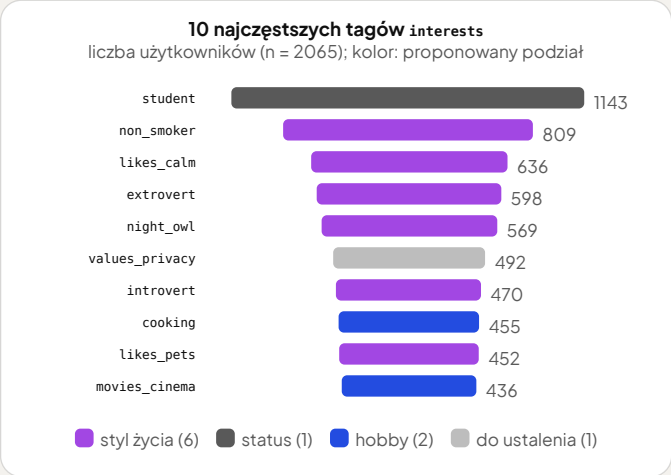
- **Jednostka:** swipe A→B na profil, a dla matcha para {A, B}. Użytkownik występuje w wielu parach, więc foldy i bootstrap robimy po użytkownikach.
- **Próba główna** (bez progu aktywności i bez wykluczania kont skrajnych): 1583 swipujących z 2065 użytkowników, 95 144 swipe'ów, 7790 par z decyzją obu stron, 487 matchy. 246 matchy z jednym swipe'em jest poza modelem.
- **Wykluczenie:** 45 kont z Hyderabad (anomalia dla polskiej aplikacji) wraz z ich swipe'ami. Kategoria „inne" zostaje.
- **Wrażliwość:** próg ≥ 10 swipe'ów daje 7538 par i 470 matchy. Bez kont skrajnych (18 z samymi prawymi, 359 z samymi lewymi swipe'ami) zostaje 5527 par.
- **Jednorodność:** `student` ma 55% użytkowników, pasmo 18–20 54%, `search_goal` = LR 92%. Miasta: Wrocław 34%, „inne" 28%, Warszawa 15%.

4. Wyniki wstępnej eksploracji

Opis bez wnioskowania. Dane wstępne: bieżąca płeć z `users`, surowe tagi, z Hyderabad.

Lejek: 95 144 swipe'ów na profile → 19 495 prawych (20,49%) → 733 matche (7,52% prawych) → 269 matchy z rozmową (36,70%). 246 matchy (33,6%) ma zapisany tylko jeden swipe, a z 2742 rozmów 2310 nie pochodzi ani z matcha, ani z ogłoszenia. 1220 z 7790 par (15,66%) zdecydowało tego samego dnia.

[1] Odrzuciliśmy dwie hipotezy wymagające kolejności zdarzeń w ciągu dnia (dopasowanie dwustronne, zgodność selektywności; dawne H3 i H4). Dane mają tylko `day`, a po filtrach zostaje 2308 par i 87 matchy.



Rys. 1. Styl życia w tagach `interests` i w polach strukturalnych. Lewy: 10 najczęstszych surowych tagów (`EDA`, „Analiza zainteresowań"). Kolor to wstępny podział według D12, D15 i dokumentu technicznego (`values_privacy` nieprzypisany); `cooking` i `movies_cinema` jako hobby to propozycja przed zamrożeniem codebooka. Prawy: pary tag–pole wskazane w dokumencie technicznym (H1, plan pomiaru) i braki pól z `users_overview`. Liczności tagów pozostałych par nie były liczone. Surowe tagi z duplikatami formatów, z Hyderabad.

Aktywność

- Mediana 26 swipe'ów na użytkownika (średnia 60,1; p95 ≈ 250; maks. 646). 231 kont (14,59%) ma mniej niż 5 swipe'ów.
- Selektywność (odsetek prawych): mediana 4,4%, średnia 17,4%.
- Duże różnice między użytkownikami uzasadniają efekty losowe i wrażliwość na konta skrajne.

Styl życia i tagi, H1 (Rys. 1)

> **Styl życia jest zapisany w dwóch miejscach:** w 7 polach strukturalnych, które są w większości puste, i w tagach `interests`, które mieszają styl życia z hobby i statusem. Bez rozdzielenia tagów blok „zainteresowań" w H1 mierzyłby po części styl życia.

- **Pola strukturalne:** pięć pól stylu życia ma 74–81% braków. `cleanliness` i `noise_level` mają tylko 1,0% i 1,2% braków, ale dominująca kategoria ma 53,0% i 50,4%, co może być wartością domyślną. Kody nie mają codebooka.
- **Tagi `interests` to nie tylko zainteresowania:** wśród 10 najczęstszych tagów 6 opisuje styl życia (np. `non_smoker` 809, `likes_calm` 636, `night_owl` 569 użytkowników), 1 status (`student`, 1143), a tylko 2 to hobby (`cooking`, `movies_cinema`).
- **Ta sama cecha w dwóch miejscach:** tag `non_smoker` ma 809 użytkowników, a pole `smoking` jest puste u 1637 (79,3%). Podobne pary: `quiet_after_22`/`quiet_evenings` i `noise_level`, `loves_cleanliness` i `cleanliness`.
- **Skutek dla H1:** Jaccard tagów w 733 matchach (średnia 0,146, mediana 0,125) liczono na surowych tagach, więc obejmuje też styl życia i status. Przed modelem dzielimy tagi (D12), polu dajemy pierwszeństwo przed tagiem (D13) i ujednolicamy formaty.
- **Formaty tagów:** 124 surowe ciągi, w tym 54 formy emoji obok snake_case. 256 użytkowników ma oba formaty (159 z nich na limicie 9). 57% ma 9 tagów, 2,57% żadnego.

Demografia, H2 (Rys. 2, Rys. 3)

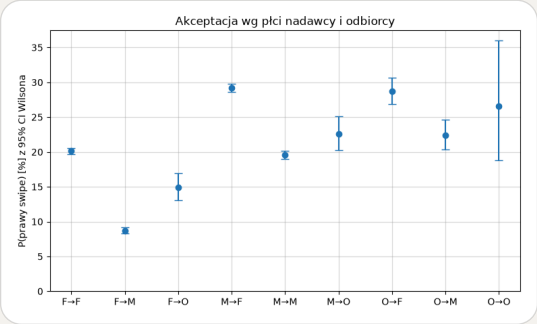
- Ta sama vs różna płeć: kobiety 20,1% vs 9,2% (F→M 8,7%, CI 8,3–9,1%), mężczyźni 19,5% vs 28,9% (M→F 29,2%).
- Żadna komórka nie jest bliska zeru. Komórki z `0` są małe (O→O: 98 swipe'ów).
- Wiek: to samo vs różne pasmo daje 21,2% vs 20,0%, ale liczy się kierunek: 18–20 → 18–20 20,4%, 18–20 → 27–30 6,6%. 65% wyświetleń dotyczy profili 18–20.

Bio, H3

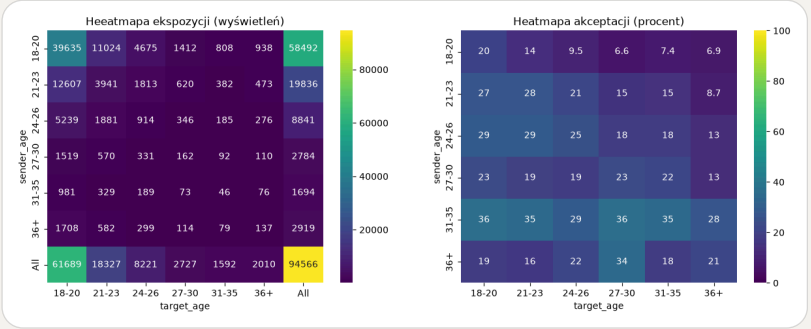
- Bio ma 1102 z 2065 profili (53,4%). Mediana 81 znaków (IQR 33–153), sufit 250.
- P(prawy): 21,5% dla odbiorców z bio, 19,2% bez bio (bez kontroli; wykres: `EDA`, „Bio").

Wersje profilu

- 4508 wersji, ostatnia zgodna z `users` w 100% pól. Płeć zmieniło 87 użytkowników (65 do `0`), wiek 12, miasto 118; `changed_fields` pomija zmiany płci, więc porównujemy snapshoty.
- Swipe'y: 46,9% z dnia pierwszej wersji, 52,5% z wcześniejszą wersją, 551 przed pierwszą, 148 bez historii (liczone na 116 414 swipe'ach razem z ogłoszeniami). DO PRZELICZENIA dla 95 144 swipe'ów na profile



Rys. 2. P(prawy swipe) według płci nadawcy→odbiorcy z 95% CI Wilsona; 95 144 swipe'ów. Podstawa: `EDA`, „H2: przedziały ufności". CI niezgrupowane po użytkowniku, więc zaniżone. `0` interpretujemy ostrożnie. *wstępne: bieżąca płeć z `users`, surowe tagi, z Hyderabad.*



Rys. 3. Wyświetlenia (lewy) i odsetek prawych swipe'ów (prawy) według pasma wieku nadawcy (wiersze) i odbiorcy (kolumny); 94 566 swipe'ów z `age_band`. Podstawa: `EDA`, „ekspozycji oraz stopnia akceptacji". Komórki 27+ są małe; w analizie łączymy je (D9). Z Hyderabad.

5. Plan pomiaru zjawiska

Wersja profilu w dniu swipe'a: cechy bierzemy z ostatniej wersji sprzed dnia swipe'a (`prior_version`), dla swipe'ów z dnia pierwszej wersji lub wcześniejszych z v1 (`first_version`), a dla 9 użytkowników bez historii z bieżącego `users` (`users_current`).

Bloki zmiennych (1–3 skalary na blok, D16)

- **Demografia:** płeć nadawcy × odbiorcy (`0` jako osobna kategoria), ta sama płeć, różnica pasm wieku ze znakiem i to samo pasmo (pasma 27+ połączone).
- **Styl życia:** zgodność 7 pól, gdy obie strony je wypełniły („brak danych" jako kategoria); konflikt kierunkowy tagów (np. `non_smoker` vs `smoker/vapes`); liczba wspólnych tagów. Pole ma pierwszeństwo przed tagiem, a tag uzupełnia braki.
- **Zainteresowania:** tagi hobby po ujednoliceniu i deduplikacji, czyli Jaccard i liczba tagów. `student` to status; zwierzęta i `extrovert/introvert` należą do stylu życia.
- **Bio (H3a):** pusty/niepusty, długość liczona z tekstu.

Model i testy

- Regresja logistyczna dla `y_right`; match w modelu drugorzędnym (7790 par).
- Estymator: regresja logistyczna z krzyżowymi efektami losowymi (wyraz wolny nadawcy i odbiorcy) dla H2 i H3. Dla H1 pooled logit z błędami klastrowanymi dwukierunkowo (nadawca, odbiorca), oceniany w foldach po użytkownikach. Jeśli GLMM nie osiągnie zbieżności, H2 i H3 liczymy pooled logitem z klastrowaniem dwukierunkowym, a H3 raportujemy bez twierdzenia o kontroli popularności.
- Kontrole: `same_city` (trzy poziomy: to samo miasto / inne / nieznane dla „inne"). Popularność i hojność jako efekty losowe odbiorcy i nadawcy w GLMM.
- Walidacja w foldach po użytkownikach; metryki logloss, AUC, AUC-PR.
- **H1:** ΔlogLoss i ΔAUC po dodaniu bloku, w obu kolejnościach, z CI z bootstrapu po użytkownikach i baseline'em z tasowania bloku. Analiza per pole jest drugorzędna.
- **H2:** iloraz szans z CI. **H3:** efekt bio z kontrolą liczby tagów i kompletności profilu.

Instrument AI

- Normalizacja tagów (124 surowe ciągi, w tym 54 formy emoji → kanoniczne snake_case): agent generuje mapowanie, człowiek je przegląda i poprawia. Miara: odsetek mapowań poprawionych przez człowieka, z listą korekt.
- Podział tagów (styl życia / status / hobby / do ustalenia): agent proponuje etykiety, człowiek etykietuje niezależnie, bez wglądu w propozycje agenta. Miara: κ Cohena agent–człowiek z 95% CI (bootstrap po tagach), uzupełniona o odsetek zgodności i macierz pomyłek.
- Propozycje agenta zapisujemy przed zamrożeniem codebooka. Wersję końcową ustala człowiek, a rozbieżności są raportowane, nie ukrywane.
- Ewentualne NLP w H3: gold standard z ręcznie oznaczonej próbki, lokalnie. Rozmiar próbki i adnotatorzy są nieustaleni.

Analizy wrażliwości

1. Próg ≥ 10 swipe'ów i bez kont skrajnych.
2. Tylko swipe'y z `prior_version`; cechy z bieżącego `users`.
3. Z kontami Hyderabad.
4. Bez kategorii „brak danych" oraz bez `cleanliness/noise_level`.
5. Dla matcha: z 246 matchami z jednym swipe'em.

6. Ograniczenia danych i możliwe źródła błędu

- **Match ≠ najem.** Wnioski dotyczą decyzji w aplikacji. Badamy związki, nie przyczyny.
- **Ekspozycja:** widzimy tylko pary pokazane przez feed. Filtry i ranking mogą zawężać wariancję, np. płci.

- **Czas tylko w dniach:** dla 46,9% swipe'ów wersja v1 jest przybliżeniem; 551 swipe'ów jest sprzed pierwszej wersji, a dzień zerowy jest nieznany.
- **Pomiar stylu życia:** dużo braków, brak codebooka, możliwe wartości domyślne. Bloki mają różną rozdzielczość i są skorelowane, więc porównujemy je w obu kolejnościach.
- **Tagi:** sufit 9 tagów i duplikaty formatów zniekształcają podobieństwo; Jaccard zależy od liczby tagów.
- **Płeć `0`:** powstaje głównie przez zmianę płci, ma małe komórki i niejasne znaczenie.
- **Brak zdjęć:** popularność modelujemy efektem losowym, ale nie znamy jej źródła.
- **Jednorodna próba** (studenci, 18–20, kilka miast) ogranicza uogólnienie.
- **Wielość porównań:** jedna główna definicja zmiennej na blok, ustalona przed modelowaniem.

7. Wykonalność w skali kursu

- **Liczności:** `y_right` ma 95 144 obserwacji, a match 487 zdarzeń. Reguła 10 zdarzeń na zmienną pozwala na ok. 47 zmiennych (dokument techniczny, próg ≥ 10). Planujemy 1–3 skalary na blok.
- **Rdzeń:** H1 i H2 na `y_right`. H3a to jeden blok więcej w tym samym modelu; H3b tylko przy wolnym czasie.
- **Przed modelowaniem:** ujednolicenie tagów, cechy as-of, filtr Hyderabad.

8. Dane osobowe i ujawnienie użycia AI

Bio przetwarzamy tylko lokalnie i zagregowanie, bez wyświetlania treści i zewnętrznych API; przesiew regułami znalazł cyfry w 9,27% wersji bio i `@` lub link w 1 wersji, więc przed użyciem tekstu robimy pełny audyt. Kartę przygotował agent Claude Code według decyzji zespołu (`docs/prompts/m1-generation-plan.md`, review: Dominik Czech 20.10.2026 3:42); wcześniejsze użycie AI opisują `docs/ai-disclosure.md` i logi w `logs/ai/`.